



ENERGY-EFFICIENT AND CONTEXT-AWARE NETWORK SELECTION IN HETEROGENEOUS NETWORKS

Sinh viên thực hiện: Nguyễn Trọng Phúc 20224099

Phạm Đăng Bách 20223871

Trần Tuấn Tú 20223819

Giảng viên hướng dẫn: PGS. TS. Nguyễn Thành Chuyên

Bộ môn: Hệ thống viễn thông

Mã lớp học: 163175

Trường: Điện - Điện tử

Phân công nhiệm vụ chi tiết các thành viên trong nhóm:

Thành viên	Nhiệm vụ chi tiết
Trần Tuấn Tú	• Nghiên cứu mô hình năng lượng và hàm chi phí tối ưu (<i>Cost</i>). • Áp dụng kiến trúc Student-Teacher; nghiên cứu thuật toán Random Forest và xây dựng vector đặc trưng 18-D. • Huấn luyện mô hình AI, kiểm chứng số liệu thực nghiệm và đánh giá hiệu năng.
Nguyễn Trọng Phúc Phạm Đăng Bách	• Nghiên cứu phương trình toán học mô hình suy hao Log-Distance. • Nghiên cứu hàm xấp xỉ Sigmoid cho tỉ lệ mất gói (PLR) và mô hình hóa độ trễ BLE dựa trên Connection Interval. • Làm báo cáo tổng hợp đề tài.

Thông tin liên hệ của nhóm:

Email: phuc.nt224099@sis.hust.edu.vn

MỤC LỤC

CHƯƠNG 1. TỔNG QUAN VÀ MÔ HÌNH HÓA HỆ THỐNG	1
1 Đặt vấn đề và Động lực nghiên cứu	1
2 Mô hình hóa hệ thống	2
2.1 Thiết lập môi trường mô phỏng	3
2.2 Tham số và biến số mạng	3
3 Mô hình vật lý kênh truyền	3
3.1 Mô hình suy hao đường truyền	3
3.2 Chất lượng tín hiệu thu và Mô hình tỷ lệ mất gói	4
3.3 Mô hình độ trễ tổng hợp	5
4 Mô hình năng lượng và chất lượng dịch vụ (QoS)	6
4.1 Bảng thông thực tế và đặc thù tác vụ	6
4.2 Mô hình tiêu thụ năng lượng	6
CHƯƠNG 2. PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ XUẤT	8
1 Cơ chế ra quyết định đa mục tiêu (MCDM)	8
1.1 Hàm chi phí tổng quát	8
1.2 Cơ chế tính toán thành phần Penalty	8
2 Kiến trúc Trí tuệ nhân tạo đề xuất	9
2.1 Biện luận lựa chọn thuật toán Random Forest	9
2.2 Quy trình thu thập dữ liệu	10
2.3 Kỹ thuật đặc trưng (Feature Engineering)	11
2.4 Huấn luyện và Kiểm chứng	12
CHƯƠNG 3. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH	14

1	Hiệu quả tối ưu năng lượng	14
1.1	Phân tích mức tiêu thụ năng lượng trung bình	14
1.2	Cơ chế tối ưu thông minh	14
1.3	Trình bày kết quả đồ thị	14
2	Đảm bảo QoS	15
	 CHƯƠNG 4. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	17
1	Kết luận	17
2	Hạn chế hiện tại	17
3	Hướng phát triển tương lai (Scalability)	17

CHƯƠNG 1. TỔNG QUAN VÀ MÔ HÌNH HÓA HỆ THỐNG

1 Đặt vấn đề và Động lực nghiên cứu

Trong bối cảnh bùng nổ của kỷ nguyên Internet vạn vật, xu hướng tích hợp đa kết nối (Multi-homed IoT) đang trở thành một lộ trình phát triển tất yếu. Việc các thiết bị IoT sở hữu khả năng truy cập mạng thông qua nhiều giao thức và giao diện truyền dẫn khác nhau không chỉ tăng cường tính linh hoạt mà còn đảm bảo sự ổn định của kết nối trong các môi trường biến động.

Tuy nhiên, việc quản lý và khai thác hiệu quả các hệ thống đa kết nối này vẫn đối mặt với những thách thức đáng kể:

- **Hạn chế của thuật toán truyền thống:** Các cơ chế lựa chọn mạng phổ biến hiện nay, điển hình là thuật toán dựa trên cường độ tín hiệu nhận được lớn nhất (Max-RSSI), thường chỉ tập trung vào chất lượng đường truyền vật lý mà bỏ qua yếu tố tiêu thụ năng lượng – một chỉ số sinh tồn đối với các thiết bị IoT hoạt động bằng pin.
- **Sự thiếu đồng bộ trong điều phối:** Hiện đang tồn tại một khoảng cách lớn giữa yêu cầu đặc thù của từng tác vụ (Task Context) và khả năng đáp ứng thực tế của hạ tầng mạng. Việc thiếu một cơ chế điều phối thông minh dẫn đến tình trạng lãng phí tài nguyên mạng hoặc không đáp ứng được các tiêu chuẩn kỹ thuật cần thiết cho từng loại dữ liệu.

Xuất phát từ những thực trạng trên, nghiên cứu này tập trung vào mục tiêu xây dựng một bộ máy ra quyết định (Decision Engine) tối ưu với các khả năng cốt lõi sau:

- **Tối ưu hóa năng lượng:** Thiết lập cơ chế cân bằng thông minh nhằm duy trì mức tiêu thụ năng lượng ở ngưỡng thấp nhất có thể, từ đó kéo dài tuổi thọ vận hành của thiết bị.
- **Đảm bảo chất lượng dịch vụ (QoS):** Đáp ứng nghiêm ngặt các ngưỡng chất lượng dịch vụ khác nhau tùy theo đặc thù của từng loại tác vụ cụ thể như truyền tải video (đòi hỏi băng thông), cảnh báo khẩn cấp (đòi hỏi độ trễ thấp) hoặc giám sát định kỳ (đòi hỏi sự ổn định).



Hình 1.1 Mô hình hệ thống IoT đa kết nối

Parameter	Symbol	Unit	Wi-Fi	5G	BLE
Transmit power	P_{tx}	dBm	20	43	0
Path loss exponent	n	-	3.5	3.0	3.5
Reference distance	d_0	m	1	1	1
Shadowing deviation	σ_{sh}	dB	2.0	2.5	1.5
Noise floor	N_0	dBm	-90	-95	-90
Channel bandwidth	B	MHz	20	100	2
Spectral efficiency	η	bit/s/Hz	0.7	0.8	0.5
Base latency	Lat_{base}	ms	5	10	20
SNR threshold	$SNR_{threshold}$	dB	10	5	8
PLR sigmoid factor	k	-	1.0	1.0	1.0
Carrier frequency	f_c	GHz	2.4	3.5	2.4
Reference path loss	$PL(d_0)$	dB	40	44	40
Max throughput	R_{max}	Mbps	100	200	2

Hình 1.2 Bảng các giá trị mặc định của từng loại mạng

2 Mô hình hóa hệ thống

Trong phần này, chúng tôi trình bày các thiết lập về môi trường mô phỏng và các tham số mạng cơ sở được sử dụng để đánh giá hiệu năng của hệ thống ra quyết định.

2.1 Thiết lập môi trường mô phỏng

Để phục vụ cho việc thực nghiệm và đánh giá thuật toán, một môi trường mô phỏng không gian đã được xây dựng. Cụ thể, môi trường được thiết lập dựa trên một bản đồ mô phỏng có kích thước 1000×1000 pixels. Trong không gian này, hệ thống bố trí tổng cộng 12 trạm phát sóng (Base Stations/Access Points) tại các vị trí cố định để đảm bảo vùng phủ sóng cho các thiết bị di động.

Cấu trúc hạ tầng mạng bao gồm sự kết hợp của ba loại công nghệ truyền dẫn phổ biến, đại diện cho các đặc tính vật lý khác nhau:

- 04 trạm phát sóng mạng di động thế hệ thứ năm (5G).
- 04 trạm phát sóng mạng không dây nội bộ (Wi-Fi).
- 04 trạm phát sóng Bluetooth năng lượng thấp (BLE).

2.2 Tham số và biến số mạng

Các tham số mạng được thiết lập dựa trên các tiêu chuẩn kỹ thuật thực tế để đảm bảo tính khách quan của mô hình. Các thông số cố định bao gồm băng thông (B), công suất phát (P_{tx}) và độ trễ cơ sở (Base Latency) cho từng loại hình kết nối (5G, Wi-Fi, BLE).

Loại mạng	B (MHz)	P_{tx} (dBm)	Base Latency (ms)
5G	100	43	10
WIFI	20	20	5
BLE	2	0	20

Bảng 2.1 Thông số mạng cố định cho các loại hình kết nối

Bên cạnh các thông số cố định, mô hình còn xem xét yếu tố biến động quan trọng nhất trong hệ thống di động là khoảng cách (d) từ thiết bị IoT đến các trạm phát sóng. Biến số này đóng vai trò quyết định trong việc tính toán suy hao tín hiệu và xác định chất lượng đường truyền thực tế tại từng thời điểm.

3 Mô hình vật lý kênh truyền

3.1 Mô hình suy hao đường truyền

Để đánh giá chính xác chất lượng kết nối và mức tiêu thụ năng lượng trong môi trường thực tế, hệ thống sử dụng mô hình suy hao Log-Distance. Đây là mô hình phổ biến để ước tính sự suy giảm công suất tín hiệu theo khoảng cách truyền dẫn trong các môi trường có vật cản và nhiễu shadowing.

Công thức tổng quát của mô hình suy hao đường truyền được xác định như sau:

$$PL(d) = PL(d_0) + 10n \log_{10} \left(\frac{d}{d_0} \right) + \sigma_{sh} \quad PT 3.1$$

Trong đó, các thành phần của công thức được định nghĩa cụ thể:

- d : Khoảng cách thực tế giữa thiết bị IoT và trạm phát sóng (đơn vị: mét).
- d_0 : Khoảng cách tham chiếu, được thiết lập mặc định là 1m.
- $PL(d_0)$: Suy hao tại khoảng cách tham chiếu, được tính toán dựa trên tần số vận hành f và tốc độ ánh sáng c theo công thức:

$$PL(d_0) = 20 \log_{10}(d_0) + 20 \log_{10}(f) + 20 \log_{10} \left(\frac{4\pi}{c} \right) \quad PT 3.2$$

- n : Hệ số suy hao môi trường (Path Loss Exponent), phản ánh mức độ suy giảm tín hiệu tùy thuộc vào địa hình cụ thể.
- σ_{sh} : Nhiều shadowing ngẫu nhiên, đại diện cho hiện tượng che chắn của các vật thể trong môi trường mô phỏng.

Dựa trên các thông số kỹ thuật của từng loại hình mạng truyền dẫn, các giá trị thực nghiệm được thiết lập trong mô hình như sau:

Loại mạng	$PL(d_0)$ (dB)	n	σ_{sh} (dB)
5G	44	3.0	2.5
WIFI	40	3.5	2.0
BLE	40	3.5	1.5

Bảng 3.2 Thông số mô hình suy hao cho các loại mạng kết nối

Việc áp dụng mô hình này cho phép "Decision Engine" dự đoán được cường độ tín hiệu và chất lượng kênh truyền một cách chính xác, từ đó đưa ra các quyết định lựa chọn mạng tối ưu về cả năng lượng và hiệu năng truyền tải dữ liệu.

3.2 Chất lượng tín hiệu thu và Mô hình tỷ lệ mất gói

Chất lượng tín hiệu tại thiết bị thu là yếu tố tiên quyết ảnh hưởng đến hiệu năng của hệ thống. Cường độ tín hiệu nhận được (RSSI) và Tỷ số tín hiệu trên nhiễu (SNR) được xác định như sau:

- **Cường độ tín hiệu nhận được (dBm):**

$$RSSI = P_{rx} = P_{tx} - PL(d) \quad PT 3.3$$

- **Tỷ số tín hiệu trên nhiễu (dB):**

$$SNR = RSSI - N_0 \quad PT\ 3.4$$

Trong đó, N_0 là nhiễu nền cố định của môi trường truyền dẫn.

Để mô hình hóa độ tin cậy của kênh truyền, nghiên cứu sử dụng hàm xấp xỉ Logistic để tính toán Tỷ lệ mất gói (Packet Loss Rate - PLR). Mô hình này phản ánh chính xác sự sụt giảm chất lượng mạng khi tín hiệu yếu đi:

$$PLR = \frac{1}{1 + e^{k \cdot (SNR - SNR_{thresh})}} \quad PT\ 3.5$$

Trong đó, $SNR_{threshold}$ là ngưỡng mà tại đó PLR đạt mức 50%, và k là hệ số quyết định tốc độ suy giảm chất lượng. Trong thực tế, ngay cả khi điều kiện sóng tốt nhất, vẫn tồn tại nhiễu ngẫu nhiên gây mất gói; do đó hệ thống thiết lập mức sàn (Clamp) cho PLR là 0.1%.

Loại mạng	N_0 (dB)	k	SNR_{thresh} (dB)
5G	-95	1	5
WIFI	-90	1	10
BLE	-90	1	8

Bảng 3.3 Thông số mô hình chất lượng tín hiệu và mất gói

3.3 Mô hình độ trễ tổng hợp

Độ trễ tổng hợp (Lat_{total}) được cấu thành từ độ trễ vật lý cố định và độ trễ phát sinh do cơ chế truyền lại tại lớp MAC khi xảy ra mất gói:

$$Lat_{total} = Lat_{base} + (PLR \cdot 100 \cdot Overhead_{per_percent}) \quad PT\ 3.6$$

Trong đó:

- Lat_{base} : Độ trễ vật lý cố định (Propagation + Processing delay) của từng chuẩn mạng.
- $Overhead_{per_percent}$: Hệ số trễ phát sinh do cơ chế truyền lại tại lớp MAC. Trong hệ thống này, cứ 1% mất gói sẽ gây thêm 10 ms trễ để gửi lại gói tin đó.

Ý nghĩa của mô hình này cho thấy khi thiết bị di chuyển ra xa trạm phát, giá trị SNR giảm dẫn đến PLR tăng theo hàm mũ, khiến tổng độ trễ hệ thống vọt lên cực nhanh.

Loại mạng	Lat_{base} (ms)
5G	10
WIFI	5
BLE	20

Bảng 3.4 Độ trễ vật lý cố định của các chuẩn mạng

4 Mô hình năng lượng và chất lượng dịch vụ (QoS)

4.1 Bảng thông thực tế và đặc thù tác vụ

Bảng thông thực tế (R) được tính toán dựa trên công thức Shannon, có xét đến giới hạn phần cứng và hiệu suất phổ:

$$R = \min \left(B \cdot \log_2 \left(1 + 10^{\frac{SNR}{10}} \right) \cdot \eta, R_{max} \right) \quad PT\ 4.7$$

Trong đó:

- η : Hiệu suất phổ - hằng số.
- R_{max} : Giới hạn phần cứng.

4.2 Mô hình tiêu thụ năng lượng

Tổng năng lượng tiêu thụ (E_{total}) cho mỗi tác vụ truyền tải được xác định bởi công suất hoạt động, thời gian truyền và năng lượng đánh thức thiết bị:

$$E_{total} = (P_{tx} + P_{idle}) \cdot \frac{Size_{task}}{R} + E_{wakeUp} \quad PT\ 4.8$$

Trong đó:

- $Size_{task}$: Dung lượng dữ liệu cần truyền.

Các giá trị sử dụng trong mô phỏng:

- Monitor: 1 kb
- Alert: 50 kb
- Video: 15 MB

- P_{tx}, P_{idle} (mW) và E_{wakeUp} (mJ): Là thông số đặc tả của chipset.

Dưới đây là các thông số đặc tả chipset được sử dụng trong mô phỏng:

Mạng	P_{tx} (mW)	P_{idle} (mW)	E_{wakeup} (mJ)	η	R_{max} (Mb/s)
5G	300	15	5.0	0.8	200
WIFI	100	10	2.0	0.7	100
BLE	10	2	0.5	0.5	2

Bảng 4.5 Thông số kỹ thuật chipset và hiệu suất mạng

CHƯƠNG 2. PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ XUẤT

1 Cơ chế ra quyết định đa mục tiêu (MCDM)

Để giải quyết bài toán lựa chọn mạng tối ưu trong môi trường Multi-homed IoT, nghiên cứu đề xuất áp dụng Phương pháp Quyết định Đa tiêu chí (Multi Criteria Decision Method - MCDM). Phương pháp này cho phép hệ thống tìm kiếm điểm cân bằng (trade-off) giữa hai yếu tố mâu thuẫn trực tiếp: tối ưu hóa mức tiêu thụ năng lượng (Energy) và đảm bảo hiệu năng dịch vụ (QoS).

1.1 Hàm chi phí tổng quát

Hệ thống đưa ra quyết định dựa trên việc cực tiểu hóa hàm chi phí tổng quát (Cost Function). Hàm này được thiết lập để phản ánh trọng số ưu tiên giữa năng lượng và các hình phạt khi vi phạm cam kết chất lượng dịch vụ:

$$Cost = w_e \cdot E + w_q \cdot Penalty \quad PT 1.9$$

Trong đó:

- E : Tổng năng lượng tiêu thụ dự tính cho tác vụ (đã được định nghĩa ở chương 1).
- $Penalty$: Điểm phạt QoS, đại diện cho mức độ không đáp ứng được yêu cầu của tác vụ.
- w_e, w_q : Các trọng số điều chỉnh mức độ ưu tiên giữa năng lượng và chất lượng dịch vụ.

1.2 Cơ chế tính toán thành phần Penalty

Thành phần $Penalty$ đóng vai trò then chốt trong việc duy trì ngưỡng QoS khắt khe cho từng loại tác vụ. Điểm phạt này được cấu thành từ mức độ thiếu hụt băng thông và mức độ vượt ngưỡng độ trễ:

$$Penalty = (\Delta_{BW} \cdot \alpha) + (\Delta_{Lat} \cdot \beta) \quad PT 1.10$$

Các tham số thành phần được định nghĩa cụ thể như sau:

- $\Delta_{BW} = \max(0, BW_{req} - R)$: Độ thiếu hụt băng thông so với yêu cầu cụ

thể của tác vụ (đơn vị: Mbps). Nếu băng thông thực tế (R) đáp ứng đủ yêu cầu (BW_{req}), giá trị này bằng 0.

- $\Delta_{Lat} = \max(0, Lat_{curr} - Lat_{req})$: Độ trễ vượt ngưỡng cho phép (đơn vị: ms).
- $\alpha = 50.0$ (Bandwidth Factor): Trọng số phạt cho mỗi 1 Mbps băng thông bị thiếu hụt.
- $\beta = 2.0$ (Latency Factor): Trọng số phạt cho mỗi 1 ms độ trễ vượt mức quy định.

Tác vụ	w_e	w_q	BW_{min} (Mb/s)	Lat_{max} (ms)
Video Stream	0.4	0.6	36.0	200
Data Alert	0.3	0.7	5.0	100
Monitoring	0.8	0.2	0.1	1000

Bảng 1.1 Thông số trọng số và yêu cầu QoS cho từng loại tác vụ

2 Kiến trúc Trí tuệ nhân tạo đề xuất

2.1 Biện luận lựa chọn thuật toán Random Forest

Mặc dù thuật toán MCDM (Multi-Criteria Decision Method) mang lại độ chính xác cao trong việc tối ưu hóa đa mục tiêu, tuy nhiên việc triển khai trực tiếp trên các thiết bị IoT gặp nhiều hạn chế. Thuật toán này đòi hỏi các phép tính toán vật lý và so sánh liên tục, gây tốn tài nguyên xử lý (CPU/RAM) và tăng mức tiêu thụ năng lượng của chipset IoT.

Để giải quyết vấn đề này, nghiên cứu đề xuất chuyển đổi mô hình ra quyết định sang kiến trúc AI dựa trên cách tiếp cận Student-Teacher:

- **Mô hình Teacher:** Sử dụng thuật toán MCDM để thực hiện tính toán offline trên 36.000 kịch bản mô phỏng, từ đó dán nhãn dữ liệu tối ưu cho từng ngữ cảnh.
- **Mô hình Student:** Sử dụng thuật toán Random Forest Classifier để học lại các quyết định từ tập dữ liệu đã dán nhãn. Mô hình này cho phép ra quyết định nhanh chóng với độ phức tạp tính toán thấp, phù hợp với tài nguyên hạn chế của thiết bị IoT.

Việc lựa chọn thuật toán Random Forest (RF) làm mô hình thực thi cốt lõi thay vì các kiến trúc mạng Neural sâu (Deep Learning) được dựa trên các phân tích về tính phù hợp với hạ tầng IoT tài nguyên thấp:

- **Tối ưu hóa tài nguyên phần cứng:** Các mạng Neural sâu thường đòi hỏi cấu hình phần cứng mạnh mẽ để xử lý các lớp tích chập hoặc ma trận trọng số lớn. Ngược lại, RF dựa trên các cấu trúc cây quyết định với các phép toán so sánh nhị phân, giúp tiết kiệm đáng kể dung lượng bộ nhớ RAM và giảm thiểu chu kỳ xử lý của CPU trên thiết bị IoT.
- **Khả năng đáp ứng thời gian thực:** Nhờ quy trình suy luận đơn giản, RF đảm bảo tốc độ ra quyết định chuyển mạch gần như tức thời. Điều này đặc biệt quan trọng trong môi trường Multi-homed HetNet, nơi các quyết định chọn mạng cần được đưa ra nhanh hơn tốc độ biến động của kênh truyền để tránh làm gián đoạn dịch vụ.
- **Hiệu quả huấn luyện và tính ổn định:** Với tập dữ liệu gồm 36,000 kịch bản mô phỏng, RF cho thấy khả năng hội tụ nhanh và tính ổn định cao. Kết quả kiểm chứng chéo 5-fold (5-fold Cross-validation) với sai số thấp (± 0.0008) khẳng định mô hình có khả năng tổng quát hóa tốt mà không gặp hiện tượng quá khớp (Overfitting), một thách thức thường gặp ở Deep Learning khi dữ liệu không đủ quy mô.
- **Tính minh bạch về đặc trưng:** RF cho phép phân tích mức độ quan trọng của các đặc trưng (Feature Importance). Qua đó, hệ thống chứng minh được loại tác vụ (Task Type) chiếm trọng số cao nhất (31%) trong quyết định, phù hợp với mục tiêu ưu tiên chất lượng dịch vụ (QoS) cho các tác vụ nhạy cảm.

2.2 Quy trình thu thập dữ liệu

Dữ liệu huấn luyện được xây dựng thông qua phương pháp lấy mẫu dựa trên lưới (Grid-based sampling) để quét toàn bộ các vị trí khả thi trên bản đồ mô phỏng kích thước 1000×1000 pixels. Quy trình cụ thể như sau:

- **Phân bổ tác vụ:** Tập dữ liệu được chia đều (khoảng 33% cho mỗi loại) giữa ba nhóm tác vụ chính: Video Streaming, Alert và Monitoring để đảm bảo tính tổng quát.
- **Dán nhãn dữ liệu:** Tổng cộng 36.000 mẫu dữ liệu sau khi thu thập được gán nhãn bởi thuật toán MCDM, xác định mạng tối ưu nhất (5G, WiFi, hoặc BLE) cho từng mẫu.

```

def collect(self, num_samples: int = 36000):
    tasks = [TaskState.IDLE_MONITORING, TaskState.DATA_BURST_ALERT, TaskState.VIDEO_STREAMING]
    task_cycle = random.sample([tasks[i % 3] for i in range(num_samples)], k=num_samples)

    w, h = self.simulation_engine.map_size
    for i in range(num_samples):
        x = (i * 50) % w
        y = ((i * 50) // w * 50) % h
        pos = (min(max(x + random.randint(-25, 25), 0), w - 1),
                min(max(y + random.randint(-25, 25), 0), h - 1))

        ds = self.simulation_engine.device_state
        ds.position, ds.current_task = pos, task_cycle[i]
        self.simulation_engine._update_available_networks()
        if not ds.available_networks:
            continue

        try:
            opt_net, _ = select_best_network(ds.available_networks, self.network_configs,
            ds.current_task)
            self.samples.append(self._extract_features(ds, opt_net))
        except Exception:
            continue

    print(f"✅ {len(self.samples)} samples | Tasks: {self._get_task_distribution()} | Nets: {self._get_network_distribution()}")


```

Hình 2.1 Hàm thực hiện

2.3 Kỹ thuật đặc trưng (Feature Engineering)

Hệ thống sử dụng một vector đặc trưng 18 chiều (18-D) làm đầu vào cho mô hình Random Forest. Vector này bao gồm các thành phần:

- **Ngữ cảnh thiết bị (Device Context - 3 chiều):** Bao gồm tọa độ vị trí (x, y) và loại tác vụ hiện tại ($Task$).
- **Thông số mạng (Network Stats - 15 chiều):** Đối với mỗi loại mạng (5G, WiFi, BLE), hệ thống trích xuất 5 thông số chính: RSSI, SNR, Bandwidth, Latency và Distance.
- **Xử lý mạng không khả dụng:** Để mô hình nhận biết các mạng nằm ngoài vùng phủ sóng, nghiên cứu thực hiện kỹ thuật dán nhãn giá trị biên: $RSSI = -999$ dBm và $Distance = 9999$ m.



```
def _extract_features(device, stations):
    # 1. Device Context (3 features)
    # Task encode: video - 2, monitor - 1, alert - 0
    features = {'x': device.x, 'y': device.y, 'task':
encode(device.task)}
    # 2. Network Metrics (5 features per Network)
    for net in ['wifi', '5g', 'ble']:
        if net in available_networks:
            features.update({
                f'{net}_rssi': net.rssi, f'{net}_snr': net.snr,
                f'{net}_bw': net.bw, f'{net}_lat': net.lat,
                f'{net}_dist': calc_dist(device.pos, station.pos)
            })
        else:
            # Marker values for unavailable
            features.update({f'{net}_rssi': -999, f'{net}_dist': 9999})
    return features
```

Hình 2.2 Logic hàm trích xuất đặc trưng (extract_features)

2.4 Huấn luyện và Kiểm chứng

Quá trình huấn luyện mô hình Random Forest được thực hiện với các thiết lập nhằm đảm bảo khả năng hội tụ và tính ổn định:

- **Phân tách dữ liệu:** Tập dữ liệu 36.000 mẫu được chia theo tỷ lệ 80% cho huấn luyện (Train) và 20% cho kiểm tra (Test).
- **Kiểm chứng chéo (Cross-validation):** Áp dụng phương pháp K-fold với $K = 5$. Dữ liệu được chia thành 5 phần, luân phiên huấn luyện và kiểm chứng để loại bỏ hiện tượng quá khớp (Overfitting).
- **Tham số mô hình:** Cấu hình bộ phân loại bao gồm 100 cây quyết định (Decision Trees) với độ sâu tối đa của mỗi cây được giới hạn ở mức 15 để tối ưu hóa giữa độ chính xác và tốc độ thực thi.


```
# 1. Split Train/Test dataset
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

# 2. Training Random Forest
model = RandomForestClassifier(n_estimators=100, max_depth=15)
model.fit(X_train, y_train)

# 3. Cross Validation
cv_scores = cross_val_score(model, X_train, y_train, cv=5)
print(f"CV Mean: {cv_scores.mean():.4f} (+/- {cv_scores.std() * 2:.4f})")
```

Hình 2.3 Cấu trúc mã nguồn huấn luyện mô hình Random Forest và thực hiện Cross Validation.

```
Running 5-fold cross-validation...
CV scores: ['0.9990', '0.9988', '0.9995', '0.9995', '0.9984']
CV mean: 0.9990 (+/- 0.0008)
```

Hình 2.4 Kết quả thực thi kiểm chứng chéo 5-fold

CHƯƠNG 3. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

1 Hiệu quả tối ưu năng lượng

Sau khi huấn luyện và triển khai mô hình AI (Random Forest) dựa trên tri thức từ bộ máy ra quyết định MCDM, chúng tôi tiến hành đánh giá hiệu năng hệ thống thông qua các chỉ số tiêu thụ năng lượng thực tế trên từng tác vụ.

1.1 Phân tích mức tiêu thụ năng lượng trung bình

Dựa trên kết quả thực nghiệm, thuật toán AI đề xuất đạt mức tiêu thụ năng lượng trung bình ấn tượng là 20.32 mJ cho mỗi tác vụ. Để làm rõ ưu thế của phương pháp nghiên cứu, chúng tôi thực hiện so sánh đối chiếu với các thuật toán truyền thống và các cơ chế cơ bản sau:

- **Max-RSSI:** Lựa chọn mạng dựa trên cường độ tín hiệu mạnh nhất.
- **Random:** Lựa chọn mạng ngẫu nhiên.
- **Min Energy / Min Latency:** Các phương pháp cực đoan chỉ tối ưu duy nhất một chỉ số.
- **Rule-Based:** Cơ chế chọn mạng theo quy tắc cố định dựa trên loại tác vụ (ví dụ: Video mặc định dùng 5G, Alert dùng Wi-Fi, Monitoring dùng BLE).




Kết quả so sánh cho thấy mô hình AI không chỉ vượt trội về mặt năng lượng trung bình mà còn duy trì được sự ổn định ở các ngưỡng tối hạn (95th Percentile Energy).

1.2 Cơ chế tối ưu thông minh

Sự khác biệt cốt lõi giúp thuật toán AI đạt hiệu quả cao nằm ở khả năng nhận diện các vùng "Hotspot" – nơi có sự chồng lấn của nhiều loại sóng phủ. Thay vì duy trì kết nối 5G công suất cao một cách liên tục như thuật toán Max-RSSI, AI đề xuất chủ động chuyển hướng sang các giao diện Wi-Fi hoặc BLE ngay khi ngữ cảnh tác vụ cho phép mà vẫn đảm bảo không vi phạm các ngưỡng QoS.



1.3 Trình bày kết quả đồ thị

Dưới đây là các biểu đồ so sánh mức tiêu thụ năng lượng giữa phương pháp đề xuất (Proposed) và các phương pháp đối chứng:




2 Đảm bảo QoS

Khả năng đáp ứng: Điểm phạt QoS (Penalty) của AI duy trì ở mức thấp (0.03), tương đương với Max-RSSI




Phân tích Feature Importance: Loại tác vụ (Task_Type) chiếm trọng số quan

trọng nhất (31%) trong quyết định của AI, cho thấy mô hình đã học được cách ưu tiên QoS cho các tác vụ nhạy cảm



Tiết kiệm năng lượng



CHƯƠNG 4. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1 Kết luận

Bên cạnh mục tiêu tiết kiệm năng lượng, khả năng duy trì chất lượng dịch vụ (QoS) là tiêu chí quan trọng để đánh giá tính thực tiễn của mô hình. Các kết quả thực nghiệm dưới đây so sánh thuật toán đề xuất (Proposed) với các phương pháp phổ biến khác.

Dựa trên dữ liệu thực nghiệm, thuật toán AI đề xuất đạt mức tiêu thụ năng lượng trung bình chỉ **20.32 mJ/task**. Khi so sánh với thuật toán Max-RSSI truyền thống (22.70 mJ) và cơ chế Rule-Based (23.98 mJ), giải pháp đề xuất cho thấy sự cải thiện đáng kể về mặt hiệu suất. Đặc biệt, tại phân vị thứ 95 (95th Percentile), mô hình đề xuất duy trì mức 162.70 mJ, thấp hơn nhiều so với mức 194.00 mJ của các phương pháp không tối ưu.

Cơ chế đạt được hiệu quả này là nhờ khả năng nhận diện thông minh các vùng "Hotspot" (vùng đa phủ sóng). Thay vì duy trì kết nối 5G công suất cao liên tục, mô hình chủ động chuyển hướng sang các giao diện Wi-Fi hoặc BLE ngay khi ngữ cảnh tác vụ cho phép (ví dụ: tác vụ Monitoring hoặc Alert) để giảm thiểu tiêu thụ năng lượng mà vẫn đảm bảo độ trễ trong ngưỡng quy định.

Nghiên cứu đã xây dựng thành công một hệ thống ra quyết định thông minh cho thiết bị IoT đa kết nối. Bằng cách kết hợp giữa lý thuyết MCDM và mô hình học máy Random Forest, hệ thống đã chứng minh được khả năng tối ưu hóa đồng thời giữa thời lượng pin và chất lượng trải nghiệm dịch vụ.

2 Hạn chế hiện tại

Mặc dù đạt được kết quả khả quan, hệ thống hiện tại vẫn tồn tại hạn chế về tính "tối ưu hóa ích kỷ" (Selfish Optimization). Do mỗi thiết bị chỉ thực hiện tối ưu dựa trên trạng thái cá nhân, hiện tượng tắc nghẽn cục bộ có thể xảy ra khi số lượng thiết bị trong một khu vực tăng lên đáng kể, gây mất cân bằng tải hệ thống.

3 Hướng phát triển tương lai (Scalability)

Để giải quyết các thách thức về khả năng mở rộng, nghiên cứu định hướng hai lộ trình phát triển chính:

- **Tiếp cận hướng mạng (Network-Centric):**

- *Cơ chế:* Dịch chuyển "bộ não" quyết định từ thiết bị lên các SDN Controller đặt tại trạm MEC (Edge Cloud).
- *Lợi ích:* Thay thế tối ưu hóa ích kỷ bằng điều phối tập trung để thực hiện cân bằng tải (Load Balancing) động giữa 5G và Wi-Fi, đảm bảo ổn định QoS cho hàng ngàn thiết bị cùng lúc.

- **Tiếp cận hướng AI (AI-Centric):**

- *Cơ chế:* Áp dụng Học máy liên minh (Federated Learning), trong đó các thiết bị huấn luyện mô hình cục bộ và chỉ gửi thông số (Weights) về server trung tâm để tổng hợp thành Global Model.
- *Lợi ích:* Cho phép các thiết bị học hỏi kinh nghiệm từ vùng phủ sóng của nhau mà không cần thu thập dữ liệu thô, giúp bảo mật quyền riêng tư tuyệt đối và tiết kiệm băng thông truyền tải lên Cloud.

TÀI LIỆU THAM KHẢO

- [1] T. S. Rappaport, “Wireless Communications: Principles and Practice”, 2nd ed., 2002.
- [2] C. E. Shannon, “A Mathematical Theory of Communication”, Bell System Tech. J., 1948.
- [3] K. Piamrat, et al., “QoE-aware Vertical Handover in Wireless Heterogeneous Networks”, IEEE Trans. Mob. Comput., 2011.
- [4] L. Breiman, “Random Forests”, Machine Learning, vol. 45, no. 1, 2001.
- [5] 3GPP, “Study on channel model for frequencies from 0.5 to 100 GHz”, TR 38.901, 2024.
- [6] B. McMahan, et al., “Communication-Efficient Learning of Deep Networks from Decentralized Data”, AISTATS, 2017.